Rapport de Travail

Classification automatique de la qualité
des images de sceaux byzantins (M0–M3)

Auteurs : Ezéchiel Sawadogo & Mamadou Diouhé Barry
Encadrement : Victoria Eyharabide & Saranga K. Mahanta
Sorbonne Université — Master 1 Langue et Informatique

1. Contexte et objectifs

Ce rapport présente les travaux réalisés dans le cadre du Hybrid Artificial Intelligence Applied to Byzantine Sigillography (BHAI) project, en complément du mémoire de Master 1. L'objectif principal est de développer une approche semi-automatique permettant d'évaluer la qualité des images de sceaux byzantins, afin d'améliorer la robustesse des pipelines de traitement automatique appliqués à ces corpus historiques.

Les sceaux byzantins présentent une qualité visuelle très variable selon leur état de conservation. Cette hétérogénéité constitue un obstacle majeur pour les modèles d'apprentissage profond qui y sont appliqués. Une classification préalable de la qualité des images permettrait de filtrer les données en amont du pipeline de détection et de classification des caractères.

2. Données et annotation

2.1 Constitution du corpus

Le corpus est constitué de 625 images de sceaux byzantins issues de quatre collections distinctes :

Collection	Nombre d'images	Labels M0-M3	Source
Adolfo Eidelstein	350	0:48 / 1:159 / 2:125 / 3:18	CSV annotés

Zacos / Tatish / Seyrig	275	0:32 / 1:113 / 2:119 / 3:11	CSV annotés
Total	625	0:80 / 1:272 / 2:244 / 3:29	—

2.2 Schéma d'annotation

Quatre niveaux de qualité ont été définis pour annoter le degré de lisibilité et de conservation du monogramme présent sur chaque sceau :

Niveau	Description
M0	Sceau en excellent état — monogramme clairement lisible
M1	Sceau en bon état — quelques défauts mineurs
M2	Sceau dégradé — lisibilité partielle
M3	Sceau très dégradé — monogramme difficilement lisible

L'accord inter-annotateur a été calculé pour valider la cohérence des annotations entre Ezéchiel Sawadogo, Mamadou Diouhé Barry, et Saranga K. Mahanta.

Le dataset présente un déséquilibre important : M1 (272 images) et M2 (244 images) dominent largement, tandis que M3 ne compte que 29 images. Ce déséquilibre a nécessité des stratégies spécifiques lors de l'entraînement.

3. Pipeline technique

3.1 Préparation des données

Les données ont été divisées selon un protocole de validation croisée stratifiée à 5 plis (StratifiedKFold), garantissant que chaque fold respecte la distribution des classes M0–M3. Chaque fold est divisé en trois ensembles :

- Train : 425 images (85% du train-val)
- Validation : 75 images (15% du train-val)
- Test : 125 images (20% du total)

3.2 Gestion du déséquilibre

Deux stratégies complémentaires ont été appliquées pour compenser le déséquilibre des classes :

- Class Weights : pondération des classes dans la fonction de perte (CrossEntropyLoss), calculée via sklearn.utils.class_weight.compute_class_weight. M3 reçoit un poids de 5.31, contre 0.57 pour M1.
- WeightedRandomSampler : rééquilibrage des batches pendant l'entraînement — M0 et M3 sont tirés plus fréquemment.

3.3 Augmentation des données

Les transformations suivantes ont été appliquées aux images d'entraînement pour améliorer la généralisation :

- Retournement horizontal et vertical aléatoire
- Rotation aléatoire jusqu'à 30°
- Variations de luminosité, contraste et saturation (ColorJitter)
- Conversion en niveaux de gris aléatoire (p=0.1)
- Translation aléatoire (RandomAffine, translate=0.1)

3.4 Architectures comparées

Cinq architectures de transfer learning ont été comparées, toutes pré-entraînées sur ImageNet ou une base large :

Modèle	Type	Paramètres total	Couches dégelées
ResNet-18	CNN résiduel	11.7M	layer4 + fc
ResNet-50	CNN résiduel	25.6M	layer4 + fc
EfficientNet-B0	CNN efficace	5.3M	features.5-8 + classifier
ViT-Tiny	Transformeur visuel	5.7M	blocs 9-11 + head
DINOv2-Small	Transformeur visuel	21.4M	blocs 10-11 + classifier

Pour chaque modèle, seules les dernières couches ont été dégelées celles qui apprennent les représentations les plus abstraites et spécifiques au domaine. Les premières couches, qui reconnaissent des caractéristiques génériques (contours, textures), ont été maintenues figées pour éviter l'overfitting.

4. Résultats

4.1 Performances globales

Les résultats ont été obtenus avec 20–25 epochs d'entraînement sur GPU T4 (Google Colab). Les métriques rapportées sont la moyenne et l'écart-type sur les 5 folds :

Modèle	Accuracy moy.	Écart-type	F1-macro moy.
ResNet-18	41.1%	±0.042	0.340
ResNet-50	43.8%	±0.026	0.351
EfficientNet-B0	20.5%	±0.024	0.187
ViT-Tiny	41.9%	±0.031	0.377
DINOv2-Small	46.6%	±0.052	0.419

DINOv2-Small obtient les meilleures performances sur les deux métriques, confirmant la recommandation de Saranga K. Mahanta. EfficientNet-B0 présente des résultats très faibles (20.5%), liés à un gel trop agressif du backbone.

4.2 Analyse de l'overfitting

L'analyse des courbes d'entraînement révèle un phénomène d'overfitting clair et consistant sur tous les modèles :

- L'accuracy d'entraînement atteint 90–100% dès l'epoch 15–20
- L'accuracy de validation se stabilise entre 45 et 65% sans progresser
- La loss de validation augmente ou oscille après l'epoch 10–15

ResNet-18 présente l'overfitting le plus sévère (train accuracy → 99%, val accuracy → ~50%). EfficientNet affiche l'écart le plus modéré. Ce phénomène est principalement attribuable à la taille restreinte du dataset (625 images).

4.3 Analyse des matrices de confusion sommées

Les matrices de confusion ont été sommées sur les 5 folds pour chaque modèle. Deux difficultés récurrentes sont observées :

- Confusion fréquente entre les niveaux adjacents M1 et M2 morphologiquement proches
- Détection difficile de M3 classe très sous-représentée (29 images seulement)

DINOv2-Small gère mieux les classes minoritaires grâce à ses représentations pré-entraînées sur une large base d'images non supervisées.

5. Limites et perspectives

5.1 Limites identifiées

- Dataset de petite taille (625 images) : principal facteur d'overfitting

- Déséquilibre sévère des classes : M3 très sous-représenté (29 images)
- EfficientNet trop gelé : résultats insuffisants, à retravailler
- Résultats encore en cours d'optimisation : DINOv2 à explorer davantage

5.2 Perspectives

- Dégeler davantage de blocs de DINOv2 (blocs 9, 10, 11) pour améliorer les performances
- Intégrer ce module de qualification comme filtre en amont du pipeline BHAI
- Augmenter le corpus en intégrant de nouvelles collections de sceaux
- Explorer des techniques d'oversampling synthétique (SMOTE) pour M3
- Présentation des résultats à DH2026 mini-conférence Distant Past(s) / Current Future(s), 28 juillet 2026

6. Conclusion

Ce travail propose une contribution originale à la datafication des sources médiévales en transformant la qualité visuelle d'un sceau en donnée exploitable. Le schéma d'annotation M0 –M3, validé par accord inter-annotateurs, et le pipeline de classification multiclasse constituent une base solide pour des travaux futurs.

DINOv2-Small s'impose comme l'architecture la plus prometteuse sur ce type de corpus historique de petite taille. L'intégration de ce module de qualification au sein du pipeline BHAI permettrait d'améliorer significativement la robustesse des étapes de détection et de classification des caractères grecs.